# Ταξινόμηση Ιατρικών Εικόνων με CNN, Transfer Learning και Vision Transformers

Παπαδόπουλος Ιωάννης-Ραφαήλ
ΑΕΜ: 10696

**Περίληψη**

Στην παρούσα εργασία εξετάζεται η ταξινόμηση ιατρικών εικόνων από το BloodMNIST dataset μέσω τριών διαφορετικών μεθόδων: εκπαίδευση Convolutional Neural Network (CNN) από το μηδέν, Transfer Learning με το ResNet18 και χρήση ενός μικρού Vision Transformer (DeiT-tiny). Η εργασία στοχεύει να αναδείξει τις διαφορές στην ακρίβεια, στη σύγκλιση και στην γενίκευση των μοντέλων, καθώς και τη σημασία του feature extraction και του fine-tuning σε προεκπαιδευμένα δίκτυα.

## 1 Dataset BloodMNIST

Το BloodMNIST dataset αποτελείται από έγχρωμες εικόνες (RGB) διαστάσεων 28×28 pixels, που απεικονίζουν οκτώ διαφορετικούς τύπους αιμοκυττάρων και πιο συγκεκριμένα τα εξής: βασόφιλο, ηωσινόφιλο, ερυθροβλάστη, ανεπτυγμένο κοκκιοκύτταρο, λεμφοκύτταρο, μονοκύταρρο, ουδετερόφιλο και αιμοπετάλιο (σχήμα 1). Κάθε τύπος κυττάρου στο αίμα έχει διαφορετική λειτουργία και ανάλογα με την ύπαρξη του ή μη και την ποσότητα του μπορούν να ανιχνευθούν ασθένειες ή παθήσεις. Οι αιματολόγοι μπορεί να ξοδεύουν μεγάλο χρονικό διάστημα για την ανίχνευση των αιμοκύτταρων αυτών και συνεπώς θα ήταν λογική η αυτοματοποίηση της ταξινόμησης των εικόνων αυτών μέσω νευρωνικών δικτύων για εξοικονόμιση χρόνου. Επίσης μέσω της χρήσης νευρωνικών δικτύων αποσκοπούμε στην αναγνώριση σύνθετων μοτίβων τα οποία θα μπορούσαν να βοηθήσουν τους ειδικούς στην αναγνώριση των αιμοκυττάρων σε πιο δύσκολες συνθήκες (εικόνα με θόρυβο, δύσκολη αναγνώριση λόγω επικάλυψης κλπ).

Το dataset είναι χωρισμένο σε training, validation και test splits με 11,959 , 1,712 και 3,421 δείγματα αντίστοιχα. Υπάρχει διαφοροποίηση στον αριθμό των δειγμάτων ανά κλάση στο training set ωστόσο δεν έχουμε ακραία φαινόμενα ανισσοροπίας όπως φαίνεται στον πίνακα 1.

## 2 CNN από την αρχή

Στο πρώτο μέρος σχεδιάζουμε και εκπαιδεύουμε ένα CNN από το μηδέν για την ταξινόμηση των εικόνων. Το νευρωνικό δίκτυο αποτελείται από 4 συνελικτικά blocks με κάθε block να περιλαμβάνει 2D convolution, ReLU activation και 2D MaxPooling. Τα φίλτρα είναι 32, 64, 128 και 256 σε κάθε block και το μέγεθος του kernel είναι 3x3. Στο τέλος υπάρχει ένα fully connected layer με αριθμό νευρώνων 8 (όσες δηλαδή και οι διαφορετικές κλάσεις). Τα μοντέλα που δοκιμάζονται διαφέρουν ως προς το εάν εφαρμόζεται Batch Normalization στο τέλος κάθε block, το ποσοστό του Dropout στο FCL, την τιμή του Weight Decay και το Learning Rate. Σε όλα τα παρακάτω πειράματα χρησιμοποιείται ως optimizer ο Adam, οι εποχές είναι 30, το batch size είναι ίσο με 64 και ως loss function χρησιμοποιείται η Categorical Cross Entropy.

| Κωδικός | Κλάση | Αριθμός Δειγμάτων |
|---|---|---|
| 0 | Basophil | 852 |
| 1 | Eosinophil | 2181 |
| 2 | Erythroblast | 1085 |
| 3 | Immature Granulocytes | 2026 |
| 4 | Lymphocyte | 849 |
| 5 | Monocyte | 993 |
| 6 | Neutrophil | 2330 |
| 7 | Platelet | 1643 |

Πίνακας 1: Κατανομή εικόνων ανά κλάση στο BloodMNIST

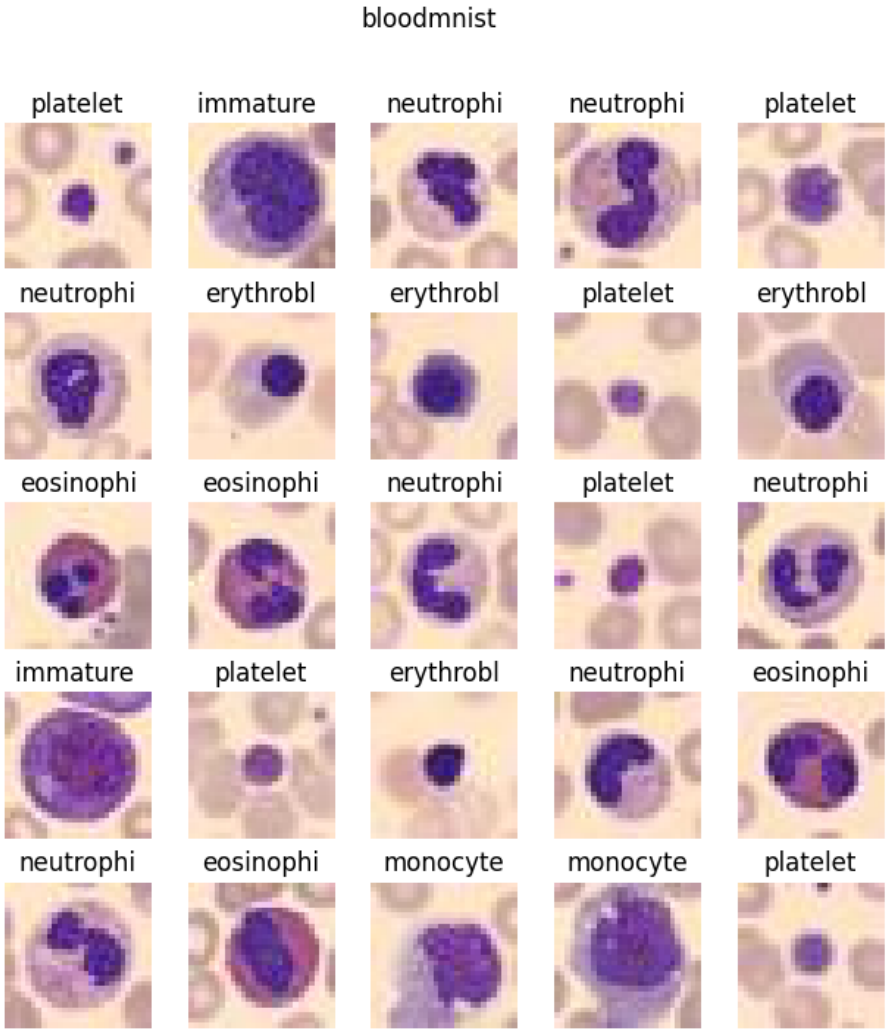


Σχήμα 1: Χαρακτηριστικά παραδείγματα εικόνων από την BloodMNIST

# 3 Ανάλυση Αποτελεσμάτων-CNN

Τα πειραματικά αποτελέσματα δείχνουν ότι η χρήση Batch Normalization βελτιώνει συστηματικά τη γενίκευση του CNN σε σχέση με το βασικό μοντέλο χωρίς κανονικοποίηση και επιταχύνει την σύγκλιση. Παρότι το μοντέλο χωρίς normalization πετυχαίνει ήδη υψηλή ακρίβεια στο test set (94.42%), η προσθήκη Batch Normalization οδηγεί σε περαιτέρω βελτίωση, με το καλύτερο απο-

τέλεσμα να επιτυγχάνεται στο πείραμα WD_1e-4 (95.06%).

Όσον αφορά το Dropout, το οποίο 'σβήνει' μερικούς νευρώνες, παρατηρείται ότι μέτριες τιμές (π.χ. 0.5) λειτουργούν ευεργετικά ως κανονικοποίηση, ενώ μικρότερες (0.2) ή μεγαλύτερες τιμές (0.7) οδηγούν σε υποβάθμιση της απόδοσης, λόγω ανεπαρκούς κανονικοποίησης ή υποεκπαίδευσης αντίστοιχα. Αντίστοιχα, το weight decay εμφανίζει έντονη ευαισθησία στην τιμή του: μικρές τιμές ($1\times10^{-4}$) βελτιώνουν τη γενίκευση, ενώ μεγαλύτερες ($1\times10^{-2}$) προκαλούν σημαντική μείωση της ακρίβειας, λόγω του περιορισμού των βαρών υποδεικνύοντας υπερβολική κανονικοποίηση. Συνολικά, τα αποτελέσματα αναδεικνύουν τη σημασία της σωστής ρύθμισης των υπερπαραμέτρων για την επίτευξη βέλτιστης απόδοσης στο σύνολο δεδομένων BloodMNIST.

| Experiment Name | Norm | Dropout | Weight Decay | LR | Test Acc. |
|---|---|---|---|---|---|
| No_Norm_No_Dropout | None | 0.0 | 0.0 | $1 \times 10^{-3}$ | 0.9442 |
| Batch_Norm | BatchNorm | 0.0 | 0.0 | $5 \times 10^{-4}$ | 0.9503 |
| Dropout_0.2 | BatchNorm | 0.2 | 0.0 | $1 \times 10^{-3}$ | 0.9161 |
| Dropout_0.5 | BatchNorm | 0.5 | 0.0 | $1 \times 10^{-3}$ | 0.9483 |
| Dropout_0.7 | BatchNorm | 0.7 | 0.0 | $1 \times 10^{-3}$ | 0.9369 |
| WD_1e-4 | BatchNorm | 0.5 | $1 \times 10^{-4}$ | $1 \times 10^{-3}$ | 0.9506 |
| WD_1e-3 | BatchNorm | 0.5 | $1 \times 10^{-3}$ | $1 \times 10^{-3}$ | 0.9424 |
| WD_1e-2 | BatchNorm | 0.5 | $1 \times 10^{-2}$ | $1 \times 10^{-3}$ | 0.8869 |

Πίνακας 2: Οι τιμές των μεταβλητών παραμέτρων σε κάθε πείραμα του CNN

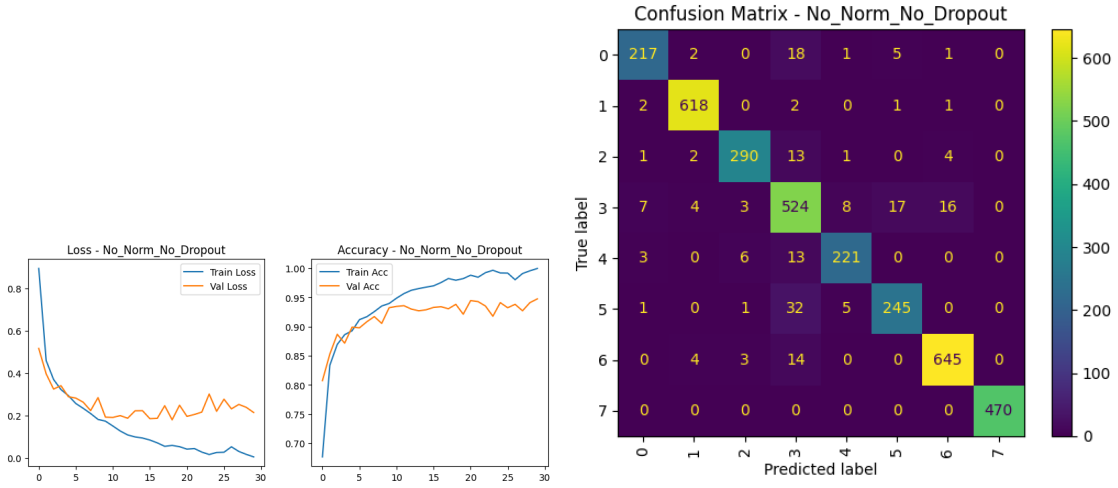


Σχήμα 2: Καμπύλες μάθησης και confusion matrix για το πείραμα 1.

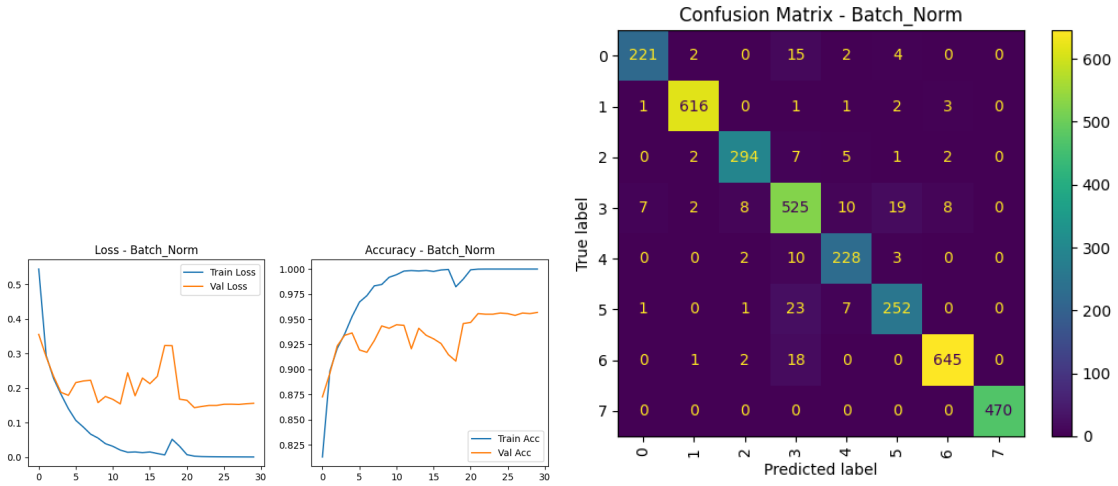


Σχήμα 3: Καμπύλες μάθησης και confusion matrix για το πείραμα 2.

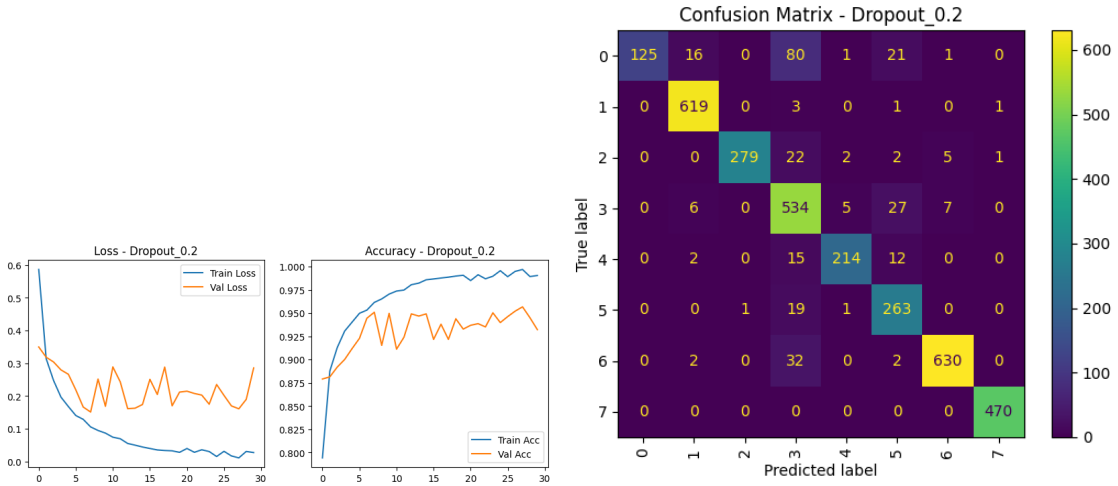


Σχήμα 4: Καμπύλες μάθησης και confusion matrix για το πείραμα 3.

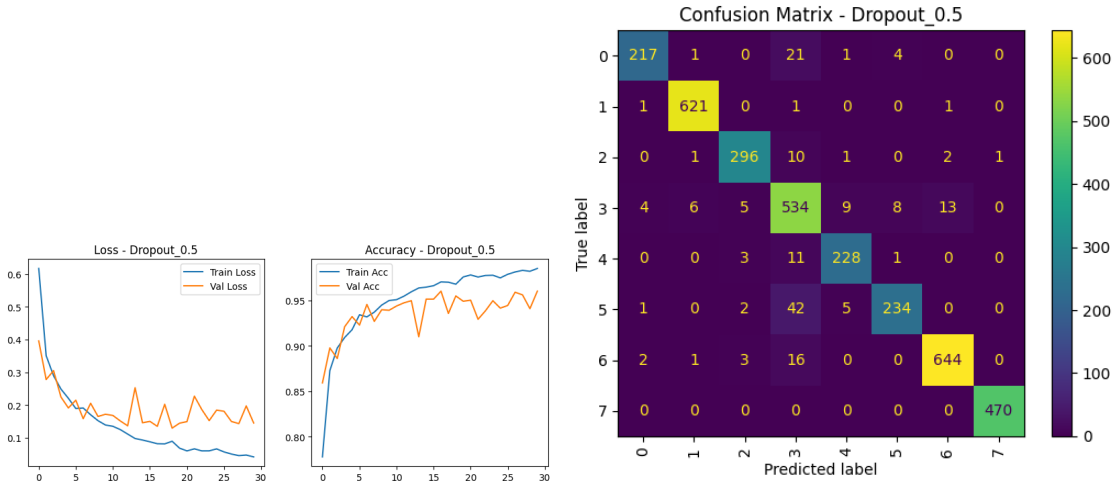


Σχήμα 5: Καμπύλες μάθησης και confusion matrix για το πείραμα 4.

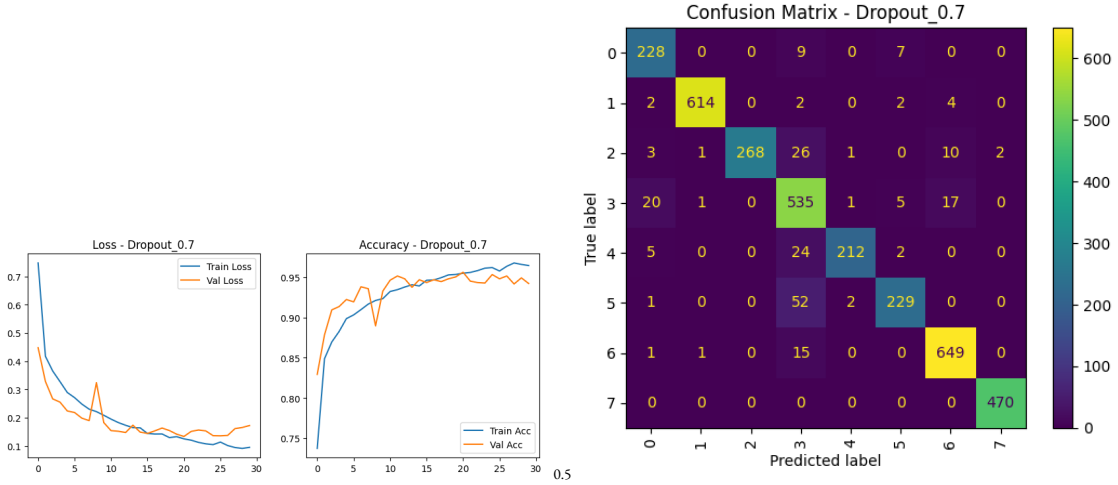


Σχήμα 6: Καμπύλες μάθησης και confusion matrix για το πείραμα 5.

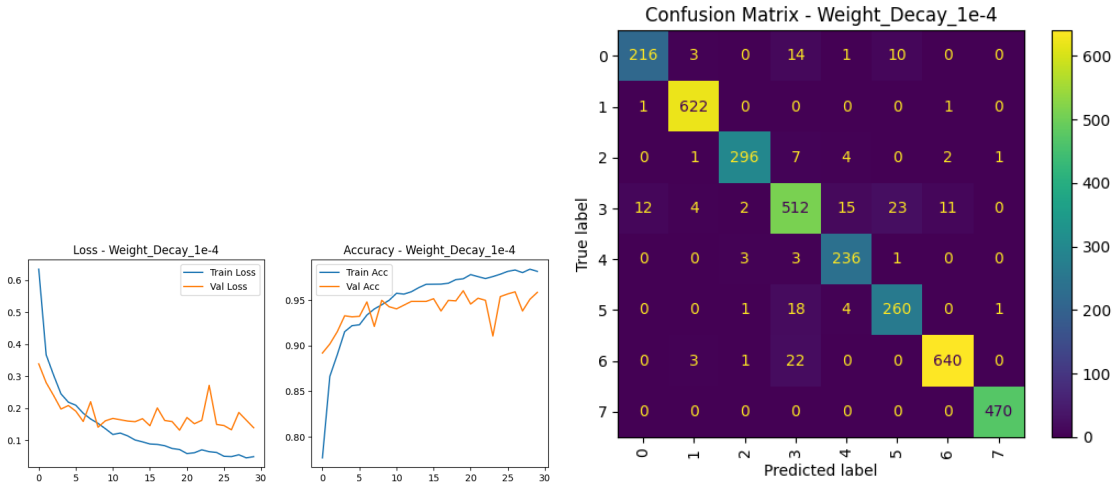


Σχήμα 7: Καμπύλες μάθησης και confusion matrix για το πείραμα 6.

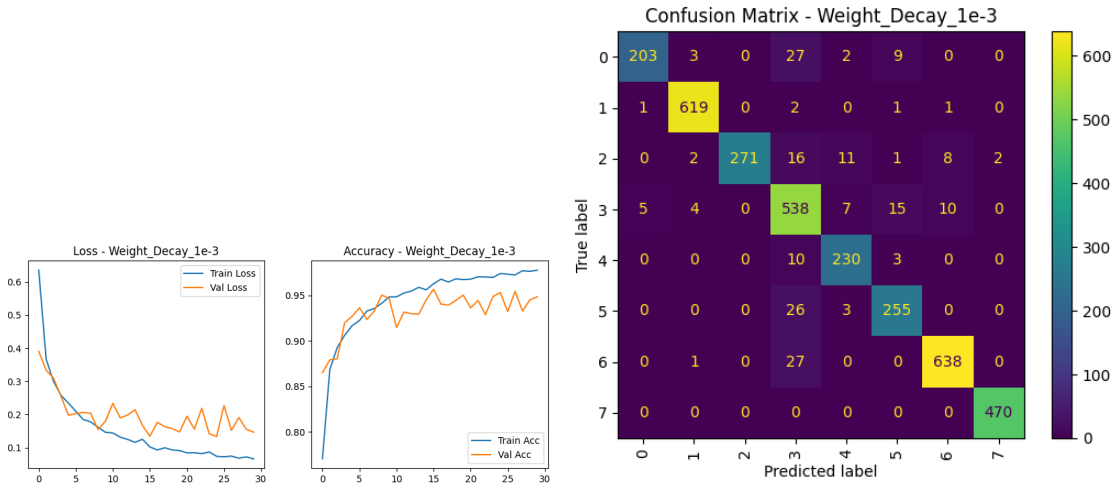


Σχήμα 8: Καμπύλες μάθησης και confusion matrix για το πείραμα 7.

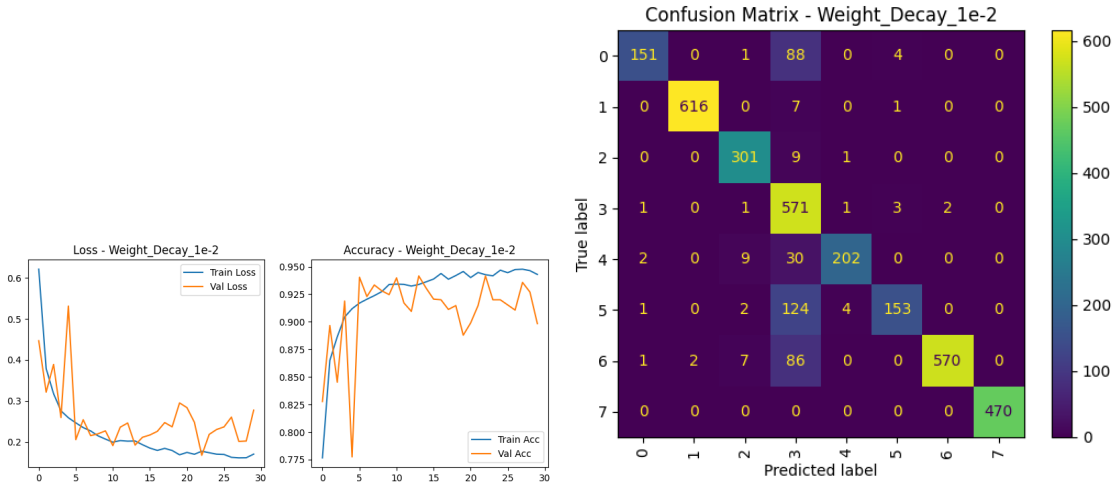


Σχήμα 9: Καμπύλες μάθησης και confusion matrix για το πείραμα 8.

# 4 Transfer Learning – ResNet18

Η δεύτερη προσέγγιση χρησιμοποιεί ένα προεκπαιδευμένο ResNet18 από το torchvision.models το οποίο έχει εκπαιδευτεί στην ImageNet το οποίο είναι ένα dataset με εκατομμύρια εικόνες από διαφορετικές κατηγορίες αντικειμένων. Αρχικά, παγώνουμε όλα τα layers εκτός του classifier head και εκπαιδεύουμε μόνο τον head, ώστε να προσαρμοστεί στις οκτώ κλάσεις του dataset. Αυτό ονομάζεται feature extraction και αξιοποιεί τα features που έχει ήδη μάθει το ResNet18 από την ImageNet, μειώνοντας τον χρόνο εκπαίδευσης και τα απαιτούμενα δεδομένα εισόδου.

Στη συνέχεια ξεκλειδώνουμε (unfreeze) τα τελευταία δύο blocks του ResNet18 και εφαρμόζουμε fine-tuning με μικρότερο learning rate. Αυτό επιτρέπει στο μοντέλο να προσαρμόσει τις παραμέτρους του στις ιδιαιτερότητες του BloodMNIST. Το fine-tuning είναι χρήσιμο όταν θέλουμε καλύτερη απόδοση ή όταν το target dataset διαφέρει σημαντικά από το dataset στο οποίο έχει προεκπαιδευτεί. Στην περίπτωση μας όπου δεν έχουμε πληθώρα δεδομένων εκπαίδευσης λόγω της φύσης των περιορισμένων πόρων σε ιατρικά δεδομένα το fine-tuning ταιριάζει απόλυτα καθώς αποκτούμε μια ιδέα πίσω από το feature extraction και classification της ImageNet και ύστερα 'προσαρμόζουμε' λίγα layers ώστε να ανταποκριθούμε στις ιδιαιτερότητες του δικού μας dataset.

Αρχικά κανονικοποιούμε και μετασχηματίζουμε τα δεδομένα κατά τις απαιτήσεις του προτύπου του ResNet18 (resize σε διάσταση 64x64 και ιδιαίτερη κανονικοποίηση προσαρμοσμένη στην ImageNet). Ύστερα για το feature extraction εκπαιδεύουμε μονάχα τον classifier head με Learning Rate 0.001, batch size 64 και Adam optimizer για 20 εποχές. Για το fine-tuning χρησιμοποιούμε Learning Rate 0.001, batch size 32 και πάλι Adam optimizer για 15 εποχές.

| Experiment Name | Optimizer | lr | Batch Size | Epochs | Test Accuracy |
|---|---|---|---|---|---|
| Feature Extraction | Adam | $1 \times 10^{-3}$ | 64 | 20 | 0.6806 |
| Fine Tuning | Adam | $1 \times 10^{-4}$ | 32 | 15 | 0.9306 |

Πίνακας 3: Transfer Learning-Σύγκριση Feature Extraction και Fine-tuning.

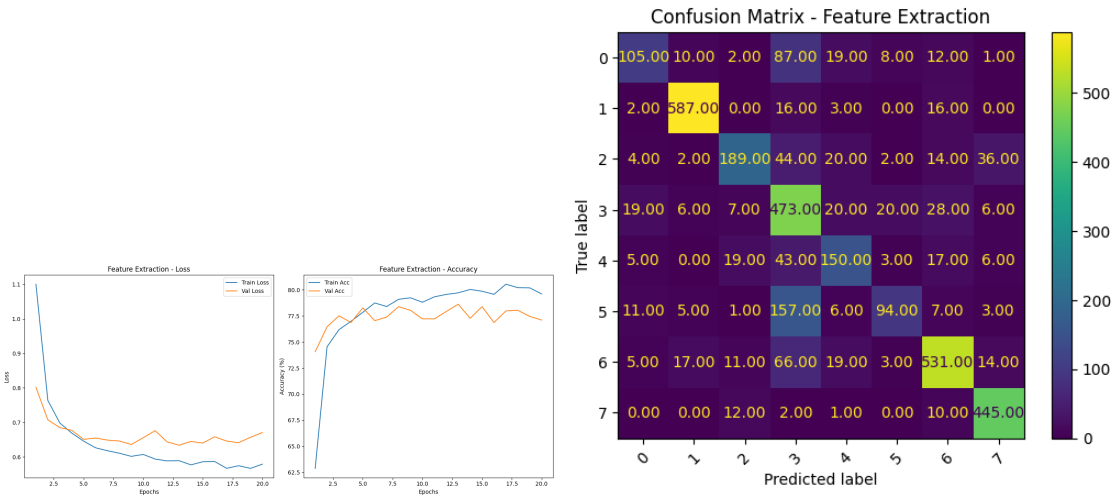


Σχήμα 10: Transfer Learning-Καμπύλες μάθησης και confusion matrix για feature extraction.

# 5 Ανάλυση Αποτελεσμάτων-Transfer Learning

Όπως φαίνεται από τα αποτελέσματα παρότι το ResNet18 έχει εκπαιδευτεί σε τελείως διαφορετικό dataset έχει μια μέτρια ακρίβεια στην κατηγοριοποίηση έστω λόγω κάποιων naive patterns

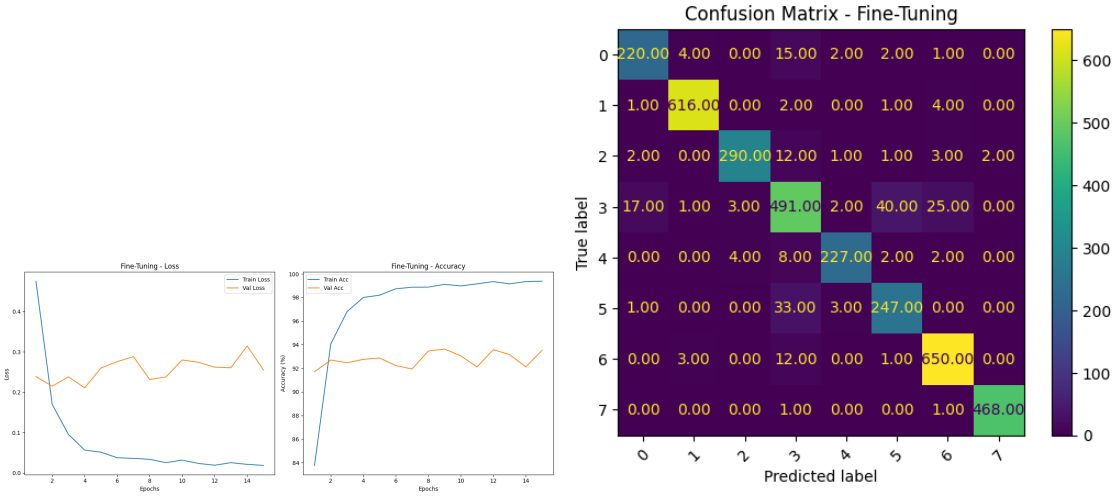


Σχήμα 11: Transfer Learning-Καμπύλες μάθησης και confusion matrix για fine-tuning.

που αναγνωρίζει. Ωστόσο η ακρίβεια (0.68) σίγουρα δεν είναι ικανοποιητική για εικόνες ιατρικού περιεχομένου όπου το ρίσκο σφάλματος είναι μεγάλο. Ωστόσο όπως φαίνεται από το fine-tuning το ξεπάγωμα μόλις δύο blocks και η εκπαίδευση αυτών εκτόξευσε την ακρίβεια στο 0.93, πολύ κοντά δηλαδή στην ακρίβεια των CNN που δημιουργήσαμε νωρίτερα χωρίς ωστόσο την ανάγκη εκπαίδεσης ολόκληρου του μοντέλου. Έτσι φαίνεται η χρησιμότητα του transfer learning που μας γλιτώνει από μεγάλο υπολογιστικό φόρτο και ανάγκη για πολλά labeled data καθώς μέσα σε λιγότερες εποχές εκπαίδευσης μερικών blocks φτάνουμε παρόμοιες αποδόσεις.

# 6 Vision Transformer (DeiT-tiny)

Οι Vision Transformers χωρίζουν την εικόνα σε μικρά patches και εφαρμόζουν self-attention για να συλλάβουν global dependencies μεταξύ των patches.

Ο Vision Transformer (ViT) προσεγγίζει το πρόβλημα της ταξινόμησης εικόνων ως ένα πρόβλημα μοντελοποίησης ακολουθιών, αντλώντας έμπνευση από τις αρχιτεκτονικές transformer που χρησιμοποιούνται στην επεξεργασία φυσικής γλώσσας.

Στον κώδικα, οι εικόνες γίνονται resize σε 224×224 και κανονικοποιούνται σύμφωνα με το πρότυπο και ο classifier head προσαρμόζεται στις οκτώ κλάσεις. Αρχικά παγώνουμε όλα τα weights και εκπαιδεύουμε μόνο τον head (feature extraction) όπως και πριν. Στη συνέχεια ξεκλειδώνουμε και πάλι τα δύο τελευταία blocks για fine-tuning. Η εικόνα εισόδου διαιρείται σε ένα σύνολο μη επικαλυπτόμενων patches σταθερού μεγέθους. Κάθε patch μετασχηματίζεται σε ένα διάνυσμα χαρακτηριστικών μέσω γραμμικού μετασχηματισμού. Στη συνέχεια, προστίθενται positional embeddings, ώστε να διατηρείται η χωρική πληροφορία και η σχετική θέση κάθε patch στην εικόνα. Τα embeddings αυτά σχηματίζουν μια ακολουθία tokens, η οποία εισάγεται στον encoder του transformer. Έτσι έχουμε αποκτήσει υψηλού επιπέδου αναπαραστάσεις που περιγράφουν την εσωτερική δομή του κάθε διαφορετικού αιμοκύτταρου και όχι μόνο τοπικές όπως στα CNNs.

# 7 Ανάλυση Αποτελεσμάτων-Transformer

Στα πειράματά μας με το BloodMNIST παρατηρήσαμε ότι κατά το στάδιο του feature extraction ο DeiT-Tiny μέσω transfer learning απέδωσε καλύτερα, ενώ το ResNet-18 έδειξε τα πλεονεκτήματά του κατά το fine-tuning, όπου η προσαρμογή των βαρών του στο συγκεκριμένο dataset οδή-

γησε σε βελτιωμένη απόδοση. Συνολικά, αυτό υποδεικνύει ότι οι Vision Transformers μπορούν να είναι πιο αποτελεσματικοί στο feature extraction, ακόμη και σε μικρά datasets, ενώ τα CNN υπερέχουν όταν γίνεται πλήρες fine-tuning.

# 8 Σύγκριση Αποτελεσμάτων

Η ανάλυση των αποτελεσμάτων δείχνει ότι τα CNN από το μηδέν χρειάζονται περισσότερα epochs για να φτάσουν σε ικανοποιητική ακρίβεια, ενώ το Transfer Learning προσφέρει γρήγορη και υψηλή απόδοση με λιγότερα δεδομένα. Οι Vision Transformers αποδίδουν καλά αλλά με αυξημένο κόστος υπολογισμού και προεπεξεργασίας. Αυτό πιθανώς να οφείλεται στο ότι το ResNet18 έχει ήδη μάθει τα γενικά μοτίβα και τα embeddings του είναι ήδη αποτελεσματικά. Αντίθετα ο Transformer ο οποίος δεν περιορίζεται σε τοπικά patterns αλλά global προσαρμόζεται στο εκάστοτε πρόβλημα με το fine-tuning και λόγω της μεγάλης του δύναμης αναγνωρίζει πιο σύνθετα μοτίβα μόλις εκπαιδευτεί έστω σε λίγα blocks. Συνεπώς η επιλογή μεταξύ των μεθόδων εξαρτάται από το μέγεθος του dataset, τους υπολογιστικούς πόρους και τον επιθυμητό χρόνο εκπαίδευσης του κάθε προβλήματος.

# 9 Προτάσεις Βελτίωσης

Μελλοντική έρευνα θα μπορούσε να εστιάσει σε hybrid CNN–Transformer αρχιτεκτονικές, σε εναλλακτικές στρατηγικές fine-tuning και στην αξιοποίηση self-supervised learning, με στόχο τη βελτίωση της απόδοσης σε μικρά ιατρικά datasets υπό περιορισμένους υπολογιστικούς πόρους.

| Experiment Name | Optimizer | lr | Batch Size | Epochs | Test Accuracy |
|---|---|---|---|---|---|
| Feature Extraction | Adam | $1 \times 10^{-3}$ | 32 | 10 | 0.8023 |
| Fine Tuning | Adam | $1 \times 10^{-4}$ | 16 | 5 | 0.8959 |

Πίνακας 4: Transformer-Σύγκριση Feature Extraction και Fine-tuning.

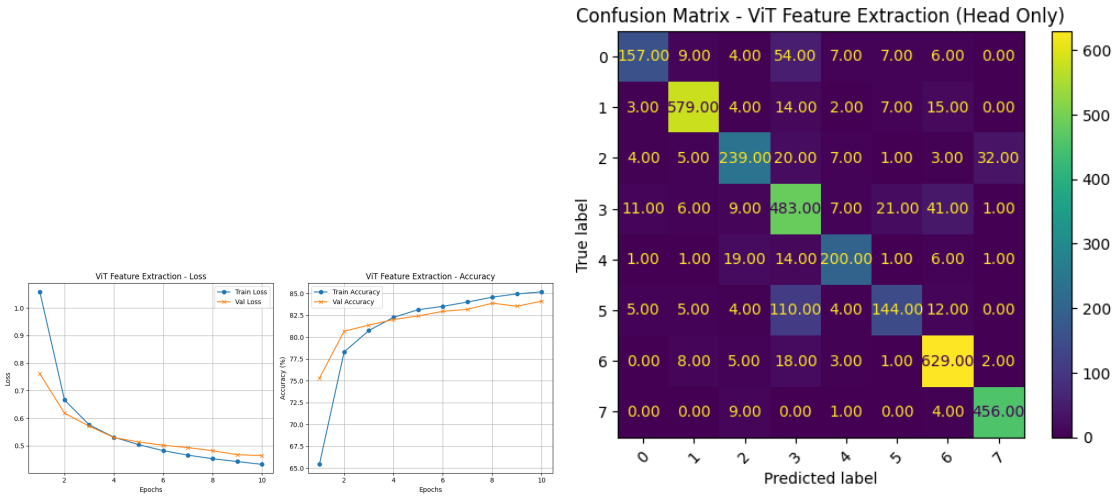


Σχήμα 12: Transformer-Καμπύλες μάθησης και confusion matrix για feature extraction.

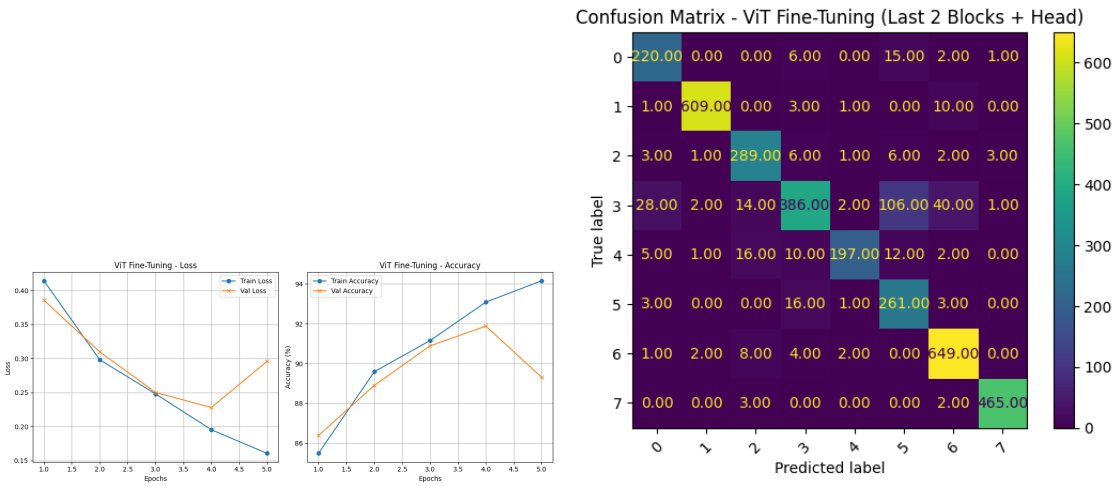


Σχήμα 13: Transformer-Καμπύλες μάθησης και confusion matrix για feature extraction.